李阳旭



男 | 年龄：22岁 | 14780162329 | lyx14780162329@gmail.com

求职意向：AI应用开发工程师

个人优势

- 精通Python，NLP，大模型应用，掌握AI领域的核心技术，能够独立开展项目开发
- 熟练使用Coze，Dify等AI应用开发平台，可快速搭建智能体用于验证
- 掌握大模型 SFT、LoRA 微调技术，可针对性优化模型适配业务场景
- 熟悉Function Call ，MCP协议，A2A协议等AI领域前沿技术，能够灵活应用到实际开发中。
- 注重细节，擅长剖析问题并提供切实可行的解决方案，能够在复杂的技术环境中高效工作
- 对工作充满热情，持续保持求知若渴的态度，不断学习新知识和技能

工作经历

上海宝思利有限公司 大模型算法 2024.11-2025.11

针对不同业务需求 ，协助开发和用于高效的AI算法；
帮助企业基于内部数据搭建RAG系统，针对不同的业务场景选用合适的模型进行微调；
通过prompt工程让模型的输出结果更符合业务需求

实习经历

南京正计通科技有限公司 算法工程师 2023.09-2024.10

负责对大规模文本数据进行清洗、去噪与结构化预处理，构建高质量训练样本，确保后续算法建模的数据可靠性；参与人才流失预测模型的训练、特征选择与超参数调优，基于逻辑回归与 XGBoost 完成多轮实验对比；对最终模型进行准确率、召回率等多指标评估，并结合业务场景对模型推理结果进行优化与验证，推动模型在实际人事流程中的落地应用。

项目经历

智能旅游助手 Agent开发工程师 2025.07-2025.11

内容：

开发一个基于大模型（LLM）的智能旅游助手，支持对用户自然语言 Query 的多意图识别，能够自动完成天气查询、景点推荐、票务查询等任务。系统结合 LLM、意图识别、槽位抽取、MCP 自动生成 SQL、MySQL 查询等模块，实现全流程自动化的实时旅游问答与信息推荐服务。

项目流程：

1. 使用大模型完成用户 Query 的意图识别与槽位抽取（地点、时间、景点类型等），并支持缺失参数追问和历史记录补全。
2. 针对复杂 Query 进行多意图路由，可同时处理天气、票务、景点推荐等多个任务，并合并结果输出。
3. 构建天气代理与票务代理，通过 MCP 自动生成 SQL 查询语句，从 MySQL 获取实时天气、票务库存与价格信息。
4. 对景点推荐类意图，结合用户偏好和目的地数据，由大模型生成结构化推荐提示词和自然语言旅游文案。
5. 将天气信息、票务结果、推荐内容等多源数据整合后，经大模型生成最终回复，实现实时、场景化的旅游智能问答体验。

业绩：

构建了 完整的“意图识别 → MCP 数据查询 → LLM 生成”链路，任务命中率相比单模型方案提升 38%+。

通过 MCP 自动 SQL 生成，将新增数据源的开发成本降低 70%，提升系统扩展效率。

实现可并行的多意图处理，使复杂查询的响应时间减少 40%。

景点推荐、票务信息、天气描述等输出自然度明显提升，用户满意度在内测评估中提升 30%+。

基于 RAG 的电商智能客服系统（一期）　大模型算法工程师　2024.12-2025.06

内容：

为海外电商平台开发了基于检索增强生成（RAG）的智能客服系统，解决了客服响应缓慢、用户投诉无人回复以及退货流 程复杂等问题。系统能够自动回答关于物流、商品和退货的查询，显著提升响应效率和准确性，为电商平台提供高效的自动化客户支持。

项目目标：

设计并实现基于 RAG 的智能客服系统，通过构建向量数据库和调用大语言模型（LLM）提升知识检索和响应生成效率。 训练混合检索模型，以优化检索结果流程。

个人职责：

1.数据预处理：对 txt、doc、pdf 等格式的数据（约 100G）进行清洗，包括去重，分段，使用paddle进行OCR识别

2.通过coze平台搭建工作流以及智能体，进行初步验证，评估效果。

3.创建 Milvus 数据库，协同整合 MySQL 数据库：

使用 qwen-embedding-v3 模型进行文本向量化；

构建 Milvus 向量数据库，支持 4 个 collection（产品、订单、物流、政策），共 600 万条。

4.构建 RAG 架构：

检索模块：使用GPT-4，通过prompt工程对 query 进行改写和拆解；

混合检索：先使用 BM25算法进行初步检索，获取与查询相关文档，再使用 embedding 模型获取另一组相关文档，最后使用 BGE-reranker-large 进行重排序，完成并取得最大相关性的结果。

增强模块：将检索模块中取得的结果，与改写后的 quary 通过格式化的 Prompt 进行融合，完成增强。

生成模块：将 Prompt 输入到 Llama-2-Chat-ms，生成文本回答。

5.LLaMA-2-Chat-ms 微调

对 LLaMA-2-Chat-ms 模型进行LoRA微调，使模型更适配电商客服场景。

微调的数据集包括：电商 FAQ 数据(约5000条)，使用GPT-4结合对话模拟生成的高质量对话数据(约2000条)

6.系统评估：

基于 RAGAS 框架，完成初步评估；

基于人工评估方法。

模型性能：

生成模型选用 LoRA微调后的Llama-2-Chat-ms(13B)，采用 RAGAS 评估框架，answer relevancy(答案相关性)=0.844；

采用 1500 条人工评估数据，准确率达 94.7%， 回复速度平均为 6.5s

压测性能测试，吞吐量为87tokens/s

业绩：

1.减少人工客服数量，并提升了全站客服响应效率；

2.服务好评率由原来的 79%提升至 93.2%；

3.显著提高了首次接触解决率（提升 15%），使更多客户问题在首次交互中得到解决。

智能文本分类系统　算法工程师　2024.07-2024.10

内容：

工具: Fasttext、Bert、Flask、Tansformers

项目描述

该项目的目的是针对各大自媒体平台以及贴吧等社区论坛发布的多元化主题文案，给文案打上精准话题标签、为视频推荐合适的分发渠道、为校园墙帖子归类到对应板块，还能为贴吧内容推荐相关讨论区，显著提升平台内容运营效率和用户体验。

项目流程

数据预处理：对爬取的数据进行清洗与处理 ，构建并切分训练数据集。

模型训练：训练Bert实现分类预测 ，准确率达到86% ，模型大小390MB。

模型优化：对比量化、蒸馏、剪枝后的模型，最后选用蒸馏后的模型，在蒸馏后，模型准确率仅降低1%，并且模型大小缩减至24.4MB。

问题分类与应用：将训练好的模型用于自动化分类平台数据，并生成报告，帮助公司识别和解决潜在问题。

模型部署：使用Docker容器化部署BERT模型。

业绩：

在蒸馏后，模型准确率仅降低1%，并且模型大小缩减至24.4MB。

帮助平台在内容分类中提升了效率和准确率，准确率由原来的73%提升至86%

人才流失预测系统　开发人员　2023.11-2024.02

内容：

工具： 逻辑回归、XGBoost

项目描述

该项目的目标是开发一套应用于企业人事的预测系统，通过分析离职原因，企业能优化工作环境和流程，提升员工工作效率和满意度，促进业务高效运行。

项目流程

数据预处理：对数据进行清洗与处理，构建并切分训练数据集。

特征工程：通过相关性筛选出与人才流失高度相关的特征，如工作满意度，月收入等，将其他无关维度进行减少。从原始数据中分析出一些不符合实际逻辑的数据并删除。减少脏数据的干扰

模型训练：使用逻辑回归作为实现分类预测，准确率达到93.27%。

模型优化：通过自动化调参工具，选用不同的正则化方案，将准确率提升至96.4%。

与人事部门沟通：将训练好的模型用于人事部门，结合实际的情况进行分析，生成报告，帮助公司减少频繁招人的成本。

业绩：

通过构建基于逻辑回归与 XGBoost 的员工离职预测模型，将预测准确率提升至 96.4%；协助人事部门提前识别高风险群体，推动多项流程优化策略落地，使关键岗位离职率在季度内下降约 12%，显著降低了企业的招聘与培训成本，提高了用工稳定性与组织运营效率。

教育经历

南京工业大学浦江学院　本科　计算机科学与技术　2021-2025

计算机设计大赛国家级三等奖（2023）

计算机设计大赛省级二等奖（2022）

校级奖学金获得者（2022）

资格证书

微软MOS Word证书　5GIOT结业证书　大学英语四级　驾驶证C1　日语N5　计算机四级